

开源持续学习的大模型：技术本体与工业商业落地观察

日期：2026-07-25

目录

- [引言](#引言)
- [1. 第1章 持续学习机制本体：抗灾难性遗忘的路线谱系](#1-第1章-持续学习机制本体抗灾难性遗忘的路线谱系)
- [2. 第2章 开源模型基座与端侧化持续训练](#2-第2章-开源模型基座与端侧化持续训练)
- [3. 第3章 开源生态与联邦持续学习](#3-第3章-开源生态与联邦持续学习)
- [4. 第4章 工业商业场景的落地检验](#4-第4章-工业商业场景的落地检验)
- [5. 第5章 产业权力格局重塑与风险治理](#5-第5章-产业权力格局重塑与风险治理)
- [结论](#结论)
- [参考文献](#参考文献)
- [待完善事项](#待完善事项)

引言

本报告的重点是**开源持续学习的大模型技术本身**，工业与商业仅作为检验技术走向产业现实的**落地观察场景**。

持续学习 (Continual / Lifelong Learning) 正把"一次性训练、静态部署"的模型范式，推向"可随数据持续演化"的活体模型。对人类意图与自然语言的高度依赖，使大模型的能力分布式编码于数十亿参数的高度纠缠空间之中，不存在可单独更新的"法语模块"或"用户偏好寄存器"；当模型顺序吸收新任务、新数据时，极易发生灾难性遗忘——这一自 1989

年被认知的现象至今被视为神经网络的"根本性局限" (Kirkpatrick et al., 2017; Zylus Research, 2026)。对以 Llama、Qwen、DeepSeek 等开放权重基座为前提的开源大模型而言，这一障碍尤为尖锐，却也正是其区别于闭源托管模型的根本机会：开放权重使抗遗忘训练、端侧微调与联邦协作均可在本地复现 (DeepSeek-AI, 2024)。

本报告以原创笔记《资源-开源持续学习重塑工业商业》作为**框架锚点**（该笔记为产业端姊妹篇视角，本身不入参考文献、稿内不自引），逐条叠加 2024-2026

年权威外部来源进行验证、修正与扩展。技术本体由四条主线构成：①

抗遗忘的**持续学习机制**（正则化 EWC/LwF、参数高效 O-LoRA/HLoRA、架构隔离

Any-SSR, arXiv:2310.14152; arXiv:2501.13669; arXiv:2503.13575）；②

开放权重基座与端侧化训练（LoRA/MeZO/GSQ-Tuning、边缘 NPU）；③

以"交易模型而非数据"为内核的**联邦持续学习与 MLOps 2.0** (Wang et al., 2025; Fortune Business Insights, 2025)；④ 支撑持续演化的**护栏治理**（EWC 锁死关键权重、LlamaFirewall 实时防御、AI 责任险, Meta, 2025）。

需要特别说明：关于"云厂商 API 税黄昏""闭源巨头的 OpenAI Dilemma""知识套利终结与大分流"三组权力格局命题，本报告**以正反证据并陈方式呈现**，属于受争议命题而非既定事实；笔记框架推演的潜在风险（物理代价、级联污染、可解释性死局、协议传染性）亦明确标注为"非既定事实"。报告全文分五章：第 1-3 章论述技术本体，第 4 章以此检验工业商业落地边界，第 5

1. 第1章 持续学习机制本体：抗灾难性遗忘的路线谱系

论点：灾难性遗忘是开源持续学习大模型的“根本障碍”

“持续学习”（Continual / Lifelong

Learning）指模型在顺序吸收新任务、新数据的过程中不灾难性遗忘已有知识 Zyllos Research, 2026。当神经网络在新任务上做梯度更新时，若覆盖了先前任务的关键权重，旧任务性能便会急剧退化——这一现象自 1989 年被认知科学命名以来，始终被视为神经网络的“根本性局限” Kirkpatrick et al., 2017。对以 Llama、Qwen、DeepSeek 等开放权重基座为前提的开源大模型而言，灾难性遗忘尤为尖锐：其通用能力分布式编码于数十亿参数的高度纠缠空间中，“不存在可单独更新的‘法语模块’或‘用户偏好寄存器’” Zyllos Research, 2026。

数据显示，遗忘并非偶然：Zyllos 引用的 2025 年比较分析（arXiv:2504.01241）证实，遗忘程度随模型规模、架构、预训练多样性与任务性质显著变化，更大模型因“容量过剩”通常遗忘较少，但**没有任何模型免疫** Zyllos Research, 2026。这正是“开源持续学习大模型”在工业商业落地前必须直面的机制性前提——无论端侧训练还是联邦生态（第2、3章），都要建立在可抗遗忘的底座之上。

论据一：正则化路线（EWC 与 LwF）

正则化思路不直接存储旧数据，而是在损失函数中施加惩罚，约束对旧任务重要权重的改动。

- **EWC（弹性权重巩固）**：Kirkpatrick 等（2017）受神经突触巩固启发，用旧任务数据的 Fisher 信息矩阵估计各权重重要性，并以二次惩罚项将其“锚定”在旧任务最优值附近，如同弹簧 Kirkpatrick et al., 2017。2025–2026 年的工程评估显示，在知识图谱链路预测任务上，EWC 将遗忘率从 12.62% 降至 6.85%（相对下降约 45.7%） Zyllos Research, 2026。不过有学者指出，EWC 依赖对角 Fisher 近似、忽略权重间相关性，在多任务序列下近似会退化 ICLR Blog, 2025。
- **LwF（Learning without Forgetting）**：Li 与 Hoiem（2017）用知识蒸馏损失保留旧任务输出，仅以新任务数据训练即可维持原能力，无需旧数据 Li & Hoiem, 2017。它在视觉分类上表现媲美联合训练，但同样受限于共享参数空间。
（旁注：在金融等工业场景中，已有综述指出智能体在“微调后忘记低风险偏好”的个案，说明遗忘会直接转化为业务回归风险 arXiv:2407.19354。）

论据二：参数高效 / 适配器路线（LoRA、O-LoRA、Replay）

参数高效微调（PEFT）只更新少量参数，天然被视为抗遗忘的轻量方案，但近年出现重要校正。

- **LoRA/PEFT**：冻结基座、仅训练低秩矩阵，显著降低算力与遗忘面。工程界一度形成“LoRA 因冻结基座而天然抗遗忘”的共识。
- **2025 年的校正之争**：2025 年论文《How to Alleviate Catastrophic Forgetting in LLMs Finetuning》明确指出，LoRA 虽参数高效，**并不能消除“功能性遗忘”（functional forgetting）**——在特定领域微调仍会损害通用能力 arXiv:2501.13669, 2025。作者据此提出分层重要性正则（HLoRA），以“路径积分”计算元素级重要性并施加正则，在 GPT-J-6B 与 LLaMA-3-3B 上以约为 EWCLoRA 二十分之一的计算、10%–15% 的存储，取得更优的通用—领域平衡 arXiv:2501.13669, 2025。这意味着“LoRA 抗遗忘”应被理解为“相对缓解”而非“免疫”，构成持续学习大模型落地中的受争议命题之一。

- **O-LoRA（正交子空间）**：为从根本上避免任务间干扰，O-LoRA 将新任务的 LoRA 训练约束在**与旧任务梯度空间正交**的方向上，使更新按构造不干扰既有知识，免回放且保留对未见任务的泛化性 O-LoRA, arXiv:2310.14152。实验显示其预测损失变化更小、隐藏状态漂移更低 O-LoRA, arXiv:2310.14152。
- **经验回放（Replay）**：保留旧任务样例与新数据交错训练，常被认为最有效，但存隐私与算力成本 Zylos Research, 2026。

论据三：架构隔离路线（正交子空间与子空间路由）

当"共享参数空间内的知识干扰"被认定为遗忘根因，一条更彻底的路线是**为不同任务分配相互隔离的参数子空间**。

- 除 O-LoRA 的正交约束外，2025 年 ICCV 提出的 **Analytic Subspace Routing (Any-SSR)** 将 LLM 下层冻结以保留通用语义，上层为每个任务维护独立 LoRA 子空间，并用递归最小二乘（RLS）闭式解训练"零遗忘"解析路由器，实现免回放、按构造不遗忘，在 Trace 指标上取得 SOTA Any-SSR, arXiv:2503.13575。
- 有学者认为，参数隔离虽彻底，但会随任务数增长带来子空间膨胀与路由开销，需在"隔离彻底性"与"参数经济"间权衡 Any-SSR, arXiv:2503.13575。这与正则化路线"稳定性—可塑性两难"形成呼应。

分析：三类路线如何构成抗遗忘工具箱

三类路线各有取舍：**正则化**侵入最小、但重要性估计困难且近似退化；**参数高效/适配器**算力友好、但 LoRA 单独使用不足以免疫；**架构隔离**按构造防干扰最彻底、却带来子空间与路由成本。Zylos (2026) 将主流策略归纳为"正则化、回放、架构、上下文窗口"四族，并指出生产级智能体正混合使用 Zylos Research, 2026。对开源大模型而言，开放权重使上述方法均可在本地复现：O-LoRA、LoRA 家族与子空间路由无需闭源 API，可由 LLaMA-Factory、Axolotl 等开源框架承载（详见第2、3章）。

小结

灾难性遗忘是"开源持续学习大模型"走向产业现实的第一道机制关卡。正则化（EWC/LwF）、参数高效与适配器（LoRA/O-LoRA/Replay）、架构隔离（正交子空间/子空间路由）三条谱系共同构成抗遗忘工具箱，其中 O-LoRA 的正交约束与 2025 年对"LoRA 非免疫"的校正，重新定义了开源模型本地持续演化的可行边界。这些机制正是后续**端侧化训练（第2章）**与**联邦持续学习生态（第3章）**赖以成立的底座——没有可靠的抗遗忘方案，边缘 NPU 上的本地微调与"以模型而非数据交易"的联邦协作都无从谈起。

数据摘要

指标	数据	来源
EWC 遗忘率（KG 链路预测）	12.62% → 6.85%（相对降约45.7%）	Zylos Research, 2026
LoRA 功能性遗忘	领域微调仍损通用能力，非免疫	arXiv:2501.13669, 2025
HLoRA 计算/存储	约为 EWCLoRA 1/20 计算、10%–15% 存储	arXiv:2501.13669, 2025
O-LoRA 特性	正交子空间、免回放、保留泛化	O-LoRA, arXiv:2310.14152
Any-SSR 特性	独立 LoRA 子空间+RLS 路由、Trace SOTA	Any-SSR, arXiv:2503.13575

2. 第2章 开源模型基座与端侧化持续训练：开放权重、边缘 NPU 与 On-device LoRA

【论点】 开源持续学习大模型能否从“论文技术”走向“可部署”，取决于一个物理前提是否被满足：开放权重基座使模型可被本地拥有与再训练，端侧化训练技术谱系将微调从云端算力下沉到边缘设备，边缘 NPU 等硬件则提供在设备上持续演化的算力底座。三者共同构成“持续学习大模型可部署”的物理基础；但这一基础目前仍有明确边界——可部署规模主要止于小模型，且“端侧训练”通常不等于“端侧全参训练”。

【论据】

2.1 开放权重基座家族：本地持续演化的前提。以 Llama、Mistral、Qwen、DeepSeek 为代表的开放权重模型，使“模型发布即冻结”的传统范式被实质性打破。DeepSeek-V3 采用 671B 总参数、每 token 激活 37B 的 MoE 架构，在 14.8T token 上预训练，全程仅耗 2.788M H800 GPU 小时，且权重已公开发布（DeepSeek-AI, 2024）。Qwen 家族截至 2026 年 1 月在 Hugging Face 累计下载超 7 亿次、衍生模型逾 18 万、开源模型近 400 个，规模居全球开放模型首位（Xinhua, 2026）。事实表明，开放权重为“本地持有一持续微调—上线演化”的闭环提供了可直接获取的前提。需指出，学界对“开源”一词作严谨校正：多数所谓“开源大模型”实为“开放权重”（open-weight），仅发布参数而非训练代码、数据与可审计许可（WhatLLM, 2026）。关于“开源逼近闭源”的强断言属受争议命题：跨基准分析显示，最优开放权重模型在综合智能指数上平均落后闭源前沿约 8 分（约合 4 个月代差），但在 LiveCodeBench、GPQA 等单项上差距已缩至 1–2 分（WhatLLM, 2026）。故“开放权重在质量甜点区逼近闭源”应视为有条件成立的观点，而非定论。

2.2 端侧化持续训练技术谱系：从云端到 ARM/NPU。

将微调搬离云端的努力已形成清晰路线谱系（EmergentMind, 2026）。参数高效路线以 LoRA/Adapters 为代表，冻结主干、仅训低秩增量。零阶优化路线中，MeZO 以仅前向的有限差分估计梯度，使训练内存与推理持平，相较反向传播最高约 12 倍内存下降，单张 A100 即可微调 30B 模型（反向传播仅能训 2.7B）（Malladi et al., 2023）。整数/低比特路线以 GSQ-Tuning 为代表，用分组共享指数整数格式替代浮点前后向，实现纯整数端侧微调，相较 FP16 内存降约 1.85 倍、相较 FP8 功耗与芯片面积分别降约 5 倍与 11 倍（Zhou et al., 2025）。面向超低资源设备，Skip2-LoRA 借助激活缓存在 ARM MCU 上将微调墙钟时间降约 90%，LoRA-Edge 用张量列分解使可训参数量降约两个数量级；结构化反向方法（如 MeSP）相较梯度检查点进一步降内存约 62%（EmergentMind, 2026）。这些技术把“持续学习”从数据中心推向手机、MCU 与 NPU。

2.3 边缘硬件支撑：NPU 在线学习仍处早期。硬件侧已出现端侧训练的真实案例。联发科在 MDCC 2025 发布基于天玑 NPU 的端侧 LoRA 训练，相较 CPU 方案提速约 50 倍，将训练时间从一整天压缩至约半小时（PChome, 2025）。AMD 则以 Llama 3.2 1B 配合 LoRA，在石油钻井每日报告（DDR）数据上微调，并将量化模型部署于 Ryzen AI NPU/iGPU 实现本地推理（AMD, 2025）——印证开放权重服务敏感场景的潜力，但须如实说明：其训练步骤在服务器级 MI300X 上完成，NPU 主要承担本地推理。分析普遍认为，“边缘 NPU 在线学习”整体仍处早期，受算力、显存与散热约束；多数移动 NPU/DSP 仅为前向推理优化、缺乏反向内核，端侧训练往往依赖零阶方法或云边协同（EmergentMind, 2026）。

2.4 Air-gapped 场景意义。开放权重与本地持续学习的组合，对流程工业、金融等"数据不出域"的隔离 (air-gapped) 场景具有直接意义：权重可离线获取，敏感数据在本地完成微调与推理，无需上传云端。GSQ-Tuning 等整数化路线还可契合仅含整数 ALU 的嵌入式设备，进一步降低隔离环境部署门槛。

【分析】 关于端侧训练前景存在张力观点。乐观方认为本地微调带来个性化、隐私与数据主权收益，且零阶/整数化路线持续突破算力边界（如 MediaTek 50 倍提速），预示"终端智能涌现"。审慎方强调当前端侧训练规模基本止于小模型（如 1B 量级），且多为 LoRA 级参数高效更新而非全参训练；NPU 反向能力缺失使大量"端侧训练"实为"端侧部署 + 服务器端训练"，训练与推理的物理位置并不总在同一设备。两方分歧并非互斥，而共同界定了技术落地的真实坐标。

【小结】 开放权重基座与端侧化训练路线共同构成"持续学习大模型可部署"的物理基础：前者提供可被本地拥有与再训练的模型本体，后者把微调能力下沉到边缘。但须清醒认识边界——可部署规模主要止于小模型，端侧训练多为参数高效更新而非全参训练，NPU 在线学习仍处早期。第 4 章将以此物理基础为参照，检验其在智能制造、金融风控与软件开发等工业商业场景中的真实落地边界。

数据摘要

指标	数据	来源
DeepSeek-V3 参数/训练	671B 总参 / 37B 激活 / 14.8T token / 2.788M H800 GPU时	DeepSeek-AI (2024)
Qwen 生态规模	下载 7 亿+ / 衍生 18 万+ / 开源近 400 模型	Xinhua (2026)
MeZO 内存下降	最高约 12×，单 A100 可训 30B	Malladi et al. (2023)
GSQ-Tuning 收益	内存降 1.85×，功耗/面积较 FP8 降 ~5×/~11×	Zhou et al. (2025)
天玑 NPU 端侧 LoRA	较 CPU 提速 ~50×，一天→半小时	PChome (2025)
开放权重综合代差	平均落后闭源约 8 分 (~4 个月)	WhatLLM (2026)

3. 第3章 开源生态与联邦持续学习：MLOps

2.0、模型版本治理与权重市场

论点： 开源持续学习的大模型正从"孤立的单一模型"升级为"持续演化的协作网络"。这一升级的制度底座由三层构成——低成本的开源迭代工具链、以"交易模型而非数据"为核心的联邦持续学习、以及把模型当作软件资产治理的 MLOps 2.0

体系；其外缘延伸出权重市场与服务层等新兴商业模式。本章聚焦生态本体，工业商业仅作参考。

论据

开源权重即"持续演化"的飞轮。开源微调工具链显著降低了社区迭代门槛：LLaMA-Factory（发表于 ACL 2024）已支持 100 余种 LLM/VLM 与 LoRA/QLoRA 微调 (LLaMA-Factory)，Axolotl 则提供声明式配置驱动的训练流程 (Axolotl)。开放权重的网络效应已被规模数据佐证：截至 2026 年初，Qwen 系列模型全球累计下载量超过 7 亿次、衍生模型逾 18 万个 (杭州网, 2026)。事实层面，这意味着任何机构都能基于开放权重进行持续微调，使模型在每个节点上"持续演化"；亦有业内观点将此类开放权重的累积效应描述为开源生态自我强化的"飞轮"。

联邦持续学习是多节点协同进化的技术底座。其核心命题是"交易模型而非数据"：各参与方在本地保留原始数据，仅交换模型参数或梯度，从而在隐私合规前提下实现协同训练。2025 年 Nature 发表的

iPFL 研究引入博弈论激励机制，以解决联邦场景下参与方贡献评估与隐私保护之间的权衡 (Wang et al., 2025 / Nature iPFL)。更宏观地，FCS 2025 综述将"联邦推理大模型"视为应对公域训练数据或在 2028 年前后逼近枯竭的"数据墙"的新赛道 (FCS 2025 联邦推理综述)。不过，联邦学习仍面临学术界的现实质疑：2025 年多项研究指出，贡献评估维度单一、激励机制公平性不足、以及差分隐私带来的精度损失，仍是落地难点 (Wang & Zhao, 2025)。

MLOps 2.0 把模型当作软件资产治理。工业场景要求模型具备可复现、可回滚、可 A-B 测试的能力，催生了"Git for Models"范式：Hugging Face 的 Model Hub 内置基于 git/git-lfs 的版本控制，支持以 commit hash、tag 或 branch 精确锁定模型版本 (Hugging Face 模型共享)；GitLab 亦于 17.6 版本将模型注册表 (Model Registry) 正式可用，提供版本、元数据与数据血缘的集中管理 (GitLab Model Registry)。需求侧增长印证了这一趋势：据 Fortune Business Insights，全球 MLOps 市场规模在 2025 年达到 29.8 亿美元，预计以 45.8% 的复合年增长率扩张，其中 BFSI (银行、金融服务与保险) 与制造业为关键垂直领域 (Fortune Business Insights, 2025)。

权重市场与商业模式：愿景与不确定性并存 (受争议命题)。愿景一侧，有观点主张"专业化微调衍生品"才是价值所在——基础模型训练动辄数十亿美元算力，而垂直微调以数百万成本捕获同等业务价值，由此催生脱敏后"进化权重层"的交易、以持续学习能力为保障的 EaaS，乃至为模型性能波动提供兜底的"模型保险" (Kwiatz, 2025)。反之，须客观指出：当前多数权重市场仍处概念或早期阶段。2025 年 1 月美国商务部工业与安全局 (BIS) 首次对"未发布的高级闭源模型权重"实施出口管制，将模型权重视作与先进芯片同等重要的战略资产 (Kwiatz, 2025)，这一监管姿态凸显了权重跨境交易在法律属性、许可边界与责任归属上的根本不确定性。因此，"权重市场将如软件代币般自由流动"目前仍属推测性命题，须与法律/技术约束平衡呈现。

服务层作为协作网络的职业化分工。在开放权重持续演化的背景下，出现了数据策展 (被视为"模型营养师")、对齐审计、以及领域蒸馏工场等专业化服务角色。Hugging Face 已从纯开源平台延伸至推理路由层，其"Inference Providers"聚合多家 GPU 供应商，标志平台向"算力路由 + 模型分发"叠加演进 (AI Star Map, 2025)；但亦有分析提醒，平台自研模型增多可能削弱其"中立分发者"定位 (AI Star Map, 2025)。

分析：三层制度底座并非孤立。开源工具链降低了"谁来迭代"的门槛，联邦持续学习解决了"数据不敢出域"的协同瓶颈，MLOps 2.0 则提供了"如何安全治理"的工程纪律；服务层与权重市场是这一网络向外溢出的商业形态。值得注意的是，模型的"持续演化"在带来敏捷性的同时，也放大了治理复杂度——版本治理与对齐审计正是为对冲这一风险而生。

小结：开源生态将"单个模型"升级为"持续演化的协作网络"。这一网络既为第 4 章工业商业落地提供了制度背景，也为第 5 章产业权力格局与风险治理埋下伏笔：当模型成为可交易、可治理、可协同演进的资产，权力与风险也将随之重新分布。

数据摘要

指标	数据	来源
Qwen 累计下载量	>7 亿次	杭州网 (2026)
Qwen 衍生模型数	>18 万个	杭州网 (2026)
MLOps 全球市场规模 (2025)	29.8 亿美元	Fortune Business Insights (2025)
MLOps 市场 CAGR	45.8%	Fortune Business Insights (2025)
公域数据"数据墙"时点	约 2028 年前后	FCS 2025 联邦推理综述

4. 第4章

工业商业场景的落地检验：智能制造、金融风控与软件开发的边界

论点

前三章分别论证了开源持续学习大模型的三组核心能力——基于抗遗忘机制的可演化私有化训练、面向端侧设备的低开销持续微调，以及以“模型而非数据”为流通对象的联邦生态。这些能力在实验室与基准层面是否成立，仍需回到产业现场检验。本章将三组技术作为“被检验对象”，以智能制造、金融风控与软件开发三个工业商业场景为观察窗口，回答一个更朴素的问题：技术边界在哪里、落地是否成立。本章的核心判断是——开源持续学习大模型在工程上已“可行”，但产业落地呈现“点状突破而非全面替代”的格局。

一、智能制造：产线活体模型的落地进度与边界

论据。

在真实产线场景，私有化部署的开源大模型已开始承接预测性维护等窄域任务。山东日照港基于 DeepSeek-R1 完成私有化部署，构建流动设备智慧运维系统，融合该港 10 年运行数据与超 40 万条记录，可提前 3–6 个月生成预测性维护计划（日照市大数据局，2025）。清华大学开源的“极数”工业结构化数据大模型，在钢铁、能源等行业的设备故障预测中将准确率提升约 15%（创业邦，2025）。这两项案例表明，企业可将多年沉淀的领域数据闭环持续注入开源基座，形成随数据演化的“活体模型”。

分析。从技术检验视角看，上述实践验证了“抗遗忘的私有化持续学习 + 开源基座”在真实产线的工程可行性：数据不出域、模型随业务数据迭代、运维决策被部分自动化。但边界同样清晰。其一，高度依赖高质量数据闭环——日照港成效建立在 10 年、40 万条记录之上，缺乏此类闭环的中小产线难以复现；其二，模型规模与任务范围偏窄，目前聚焦故障预测等可编码任务，尚未触及“工艺自主寻优”这类需跨工序协同决策的环节；其三，输出仍需人工校准，可解释性与责任归属尚未由模型独立承担。笔记框架所概括的“千厂千模”“产线活体模型”更多是当前方向的锚点而非既成现实——落地仍处在单点预测性维护阶段。

二、金融风控：分布式风控免疫的可行性与“知识套利终结”之辩

论据。

在隐私敏感的金融场景，联邦持续学习提供了不共享原始数据即可协同进化的技术路径。Nature 2025 年发表的 iPFL 框架提出“交易模型而非数据”的个性化联邦学习范式，多家机构在数据不出域前提下即可共建更鲁棒的风险识别模型（Nature，2025）；联邦学习综述亦指出其在风控等强监管场景的适配性（Federated Learning Survey，2025）。这从工程上回应了笔记框架提出的“分布式风控免疫”设想——机构以模型参数交互替代数据汇聚，形成可随各方新样本持续强化的风控网络。

分析。“分布式风控免疫”的技术可行性已被验证。然而，笔记框架进一步推演的“知识套利终结”——即企业自有进化体吞噬中低阶知识工作——属于受争议命题，须分层次辨析。**事实层面**，知识密集行业的中低阶工作确在被侵蚀：公开报道显示，麦肯锡已部署约 1.2 万乃至 2.5 万个 AI 代理处理标准化分析与文档工作，其入门级顾问招聘在 2025 年同比下降约 54%（TechOrange，2025；投资界转载，2025）。**反方观点**同样有力：高价值的咨询与法律服务仍深赖人际信任、价值判断与责任承担。法律界普遍强调，AI“无责任承担主体”，复杂案件中的价值权衡、临场博弈与情绪安抚无法被算法复刻（中华全国律师协会，2025；周兆成，2026）。因此，“知识套利终结”在“标准化、

可编码"层是可见趋势，在"高信任、高责任"层则远未成立——该命题应作为条件式判断而非既定事实呈现。

三、软件开发：企业编码生命体的路径与生态壁垒

论据。 企业可在私有环境以开源工具链持续进化代码模型。LLaMA-Factory、Axolotl 等开源框架降低了在本地微调代码大模型的技术门槛（LLaMA-Factory, GitHub; Axolotl 文档）；端侧能力也在补强——联发科 NPU 将端侧 LoRA 微调提速约 50 倍，AMD Ryzen AI NPU 支持以 Llama 3.2 1B 配 LoRA 在本地完成石油钻井日报等场景的微调（联发科，2025；AMD，2025）。这印证了"端侧持续训练 + 组织记忆固化"的工程路径。

分析。 技术路径本身成立：企业可用开源基座结合自有代码库私有化持续进化，形成沉淀组织知识的"编码生命体"。但落地边界来自成熟生态的竞争压力。**事实显示**，通用代码助手已形成极高渗透率——GitHub Copilot 2025 年用户突破 2000 万，财富 100 强企业中约 90% 已采用，其生成代码占活跃用户代码的 46%（Ruanfuji 统计，2026；Chromeosphere 统计，2026）。本地模型要在通用编码能力上超越此类商业助手，需巨额语料与算力投入。此外，对"祖传代码库"（legacy / 强领域特异性代码）的深层语义理解仍需长期积累，非短期微调可达成。故"组织记忆固化"在强隐私、强领域场景可行，全面替代通用助手尚早。

小结

综合三场景可见：开源持续学习大模型在技术上"工程可行"，但产业落地呈"点状突破而非全面替代"。智能制造验证了私有化抗遗忘训练的产线价值，却暴露对数据闭环、模型规模与人工校准的依赖；金融风控验证了联邦持续学习的"分布式免疫"可行性，亦揭示"知识套利终结"仅在标准化层成立；软件开发验证了端侧编码生命体的路径，却受成熟通用助手生态与祖传代码理解壁垒的制约。工业商业既证明了开源持续学习大模型的价值，也划出了数据闭环、规模与可解释性/责任承担的三重边界——这为第 5 章讨论风险与权力格局提供了现实依据。

5. 第5章 产业权力格局重塑与风险治理：受争议命题、特殊风险与护栏

论点

开源持续学习大模型的兴起，正在把"模型能力"从少数闭源巨头的集中托管，重新分配到企业本地与端侧。这一技术走向现实的结构后果，集中体现为三组受争议命题、一次数据主权反转，以及一类由"持续学习"自身诱发的特殊风险。需强调：格局重塑是一个"进行中、非决定性"的过程，而非已完成的结论。

论据与论证

一、受争议命题（正反证据平衡）

命题①：云厂商"API 税黄昏"、沦为"硬件管道"？

正方证据显示，开源模型在"甜点区"（中等规模、可本地部署）的总成本比闭源 API 低约 86%（whatllm, 2025），且 DeepSeek-V3 以约 2.788M H800 GPU 小时的训练成本逼近闭源旗舰水平（DeepSeek, 2024），证明开源基座可在可控成本下逼近闭源能力。反方则指出，云厂商正通过 MaaS（Model-as-a-Service）将开源权重重新收编为自身云生态入口，"API

税黄昏"未必成立；业内观点估计闭源在最高难度推理/编程任务上仍保有约 20% 的领先窗口（21 世纪经济报道, 2025）。两方证据并存，命题未定。

命题②：闭源巨头的"OpenAI Dilemma"？

一种观点认为，开源叠加持续学习稀释了闭源厂商依赖"集中训练 + API 分发"建立的"更新优势"——企业可在本地持续微调，不再被动等待厂商版本。反之，闭源方凭借集中算力与数据飞轮，仍可在前沿能力上保持代差。这是结构性张力，而非单向结论。

命题③：知识套利终结与"大分流"？

笔记框架锚定了一个命题：开源持续学习使前沿能力普及，依赖信息差获利的"知识套利"趋于终结。反方观点认为，高价值咨询、法律、医疗等场景仍依赖人际信任、责任承担与可追责主体，开源模型难以替代；且闭源在前沿仍领先。此命题须以正反证据平衡呈现，不得作为既定事实。

二、数据主权反转：进化后权重成为企业核心资产（趋势观察）

持续学习使企业本地权重沉淀了专有数据与经验，形成"模型权重资产表"的可能。Fortanix（2026）Fortanix 保密 AI 指出"模型权重就是企业新的 IP，在多数情况下，权重就是公司本身"，权重一旦泄露即可被对手复制。需指出：权重作为资产的法律定性（是否构成可计量无形资产、可否入表）目前仍不明，应作为趋势观察而非定论。

三、特殊风险（事实与潜在风险的区分）

事实层面，上海 AI Lab 等（2025，Misevolution, arXiv:2509.26354）通过实验发现，GUI Agent 在自我进化后安全对齐出现"灾难性遗忘"——面对钓鱼网站的风险触发率从 18.2% 飙升至 71.4%；基于 Qwen3-Coder 的编程 Agent 经经验积累后，对恶意代码的拒绝率从 99.4% 骤降至 54.4%，攻击成功率（ASR）从 0.6% 升至 20.6%。持续学习本身也会引入灾难性遗忘风险（Liang 等, ACM Computing Surveys, 2024）。

潜在风险（属笔记框架推演，须标注为非既定事实）：灾难性遗忘的"物理代价"（关键权重被硬锁死导致可塑性丧失）、供应链级联污染（持续学习数据/工具被污染向下游传播）、可解释性死局（进化后权重难以追溯决策依据）、开源协议传染性（GPL copyleft 是否要求本地持续学习后权重开源）。

四、护栏治理

关键权重硬锁死（对安全相关权重冻结/正则化）是笔记框架提出的方向；Zylos（2026）实证显示弹性权重整合（EWC）可将知识图谱链路预测上的灾难性遗忘从 12.62% 降至 6.85%（降幅 45.7%），为"锁死关键权重"提供方法学支撑。真实可落地的护栏方面，Meta 开源的 LlamaFirewall（2025）作为 AI Agent 实时防御层，含 PromptGuard 2、Agent Alignment Checks（链思维审计）与 CodeShield，在 AgentDojo 基准上将攻击成功率降低逾 90%（Meta, 2025; InfoQ, 2025）。对齐审计 / drift 检测 /

安全回滚亦被建议（自我训练后追加"安全微调"、在工作流插入"安全哨兵"）。模型保险 / EaaS 成为趋势：2025 年 5 月 Lloyd's 辛迪加开始承保 Armilla 的 AI 责任险（CACM, 2025）；国内首批生成式 AI 侵权责任保险在无锡落地，为雪浪工业大模型提供 70 万元保障（人保财险, 2025），保险市场以"合规级可观测性"倒逼工程透明。

小结

开源持续学习大模型对产业权力格局的重塑，是一个"进行中、非决定性"的过程：它既可能削弱云厂商的 API 税与闭源护城河，也可能被 MaaS 与前沿代差重新收编；它把模型权重变成企业资产，也把"错误进化"与对齐遗忘变成前所未有的风险。以"关键权重锁死 + 实时护栏 + 对齐审计 + 风险保险"的审慎治理框架收束全篇——技术走向现实，需要与之匹配的制度护栏。

数据摘要

指标	数据	来源
GUI Agent 自我进化后钓鱼风险触发率	18.2% → 71.4%	Misevolution (上海AI Lab, 2025)
编程 Agent 恶意代码拒绝率 (经验积累后)	99.4% → 54.4%	同上
开源甜点区 vs 闭源 API 成本优势	低约 86%	whatllm, 2025
EWC 灾难性遗忘缓解	12.62% → 6.85% (-45.7%)	Zylos, 2026
LlamaFirewall 攻击成功率降低	>90% (AgentDojo)	Meta, 2025
国内首批生成式 AI 侵权险保障额	70 万元 (雪浪工业大模型)	人保财险, 2025

结论

开源持续学习的大模型，其技术本体已具备走向工程现实的底座：**抗遗忘的持续学习机制**提供了可演化的前提，以 Llama、Qwen、DeepSeek 为代表的**开放权重基座**使模型可被本地持有与再训练，端侧化训练谱系把微调从云端下沉到边缘 NPU，而联邦持续学习与 MLOps 2.0 则把"单个模型"升级为"持续演化的协作网络" (DeepSeek-AI, 2024; Wang et al., 2025; Fortune Business Insights, 2025)。

然而边界同样清晰。端侧训练当前主要止于 1B 量级小模型，且多为 LoRA 级参数高效更新而非全参训练；多数移动 NPU 缺乏反向内核，"边缘在线学习"整体仍处早期 (EmergentMind, 2026)。产业落地呈现"点状突破而非全面替代"格局：智能制造验证了私有化抗遗忘训练的产线价值却暴露对数据闭环的依赖，金融风控验证了联邦"分布式免疫"却揭示"知识套利终结"仅在标准化层成立，软件开发验证了端侧编码生命体却受制于成熟通用助手生态 (日照市大数据局, 2025)。

在权力维度，重塑是一个"进行中、非决定性"的过程：开源持续学习既可能削弱云厂商的 API 税与闭源护城河，也可能被 MaaS 与前沿代差重新收编；它把模型权重变成企业资产，也把"错误进化"变成前所未有的风险。尤其值得警惕的是，上海 AI Lab 等的实验 (Misevolution) 显示，GUI Agent 自我进化后安全对齐出现"灾难性遗忘"——钓鱼风险触发率从 18.2% 飙升至 71.4%，编程 Agent 对恶意代码的拒绝率从 99.4% 骤降至 54.4% (Misevolution, 2025)。这要求以"关键权重锁死 + 实时护栏 (LlamaFirewall 在 AgentDojo 降攻击率逾 90%，Meta, 2025) + 对齐审计 + 风险保险"的审慎治理框架收束全篇。技术走向现实，需要与之匹配的**制度护栏**——这正是开源持续学习大模型从论文走向产业时必须回答的最后一题。

参考文献

- AMD. (2025). Accelerate LLMs locally on AMD Ryzen AI NPU and iGPU. <https://www.amd.com/pt/developer/resources/technical-articles/accelerate-llms-locally-on-amd-ryzen-ai-npu-and-igpu.html>
- Any-SSR (Analytic Subspace Routing). (2025). Analytic Subspace Routing for Continual Learning (arXiv:2503.13575). <https://arxiv.org/abs/2503.13575>
- Axolotl. (n.d.). Axolotl documentation. <https://docs.axolotl.ai/>
- CACM (ACM). (2025). AI liability insurance arrives. <https://cacm.acm.org/news/ai-liability-insurance-arrives/>

- DeepSeek-AI. (2024). DeepSeek-V3 technical report. <https://arxiv.org/abs/2412.19437>
- EmergentMind. (2026). On-device fine-tuning. <https://www.emergentmind.com/topics/on-device-fine-tuning>
- Fortune Business Insights. (2025). MLOps market size. <https://www.fortunebusinessinsights.com/zh/mlops-market-108986>
- FCS 2025 联邦推理综述 (ScienceNet). (2025). 联邦推理大模型综述. <https://news.sciencenet.cn/htmlpaper/2025/7/2025721141721983136591.shtm>
- Federated Learning Survey. (2025). A survey on federated learning (arXiv:2504.17703v3). <https://arxiv.org/html/2504.17703v3>
- Fortanix. (2026). Fortanix Confidential AI protects proprietary model IP and data. <https://www.fortanix.com/company/pr/2026/03/fortanix-confidential-ai-protects-proprietary-model-ip-and-data-for-secure-ai-inference-in-enterprise-ai-factories>
- GitLab. (n.d.). Model registry. https://docs.gitlab.com/user/project/ml/model_registry/
- HLoRA. (2025). How to alleviate catastrophic forgetting in LLMs finetuning (arXiv:2501.13669). <https://arxiv.org/html/2501.13669v2>
- Hugging Face. (n.d.). Model sharing & version control. https://huggingface.co/docs/transformers/v4.27.2/en/model_sharing
- ICLR Blog. (2025). Fisher information and EWC. <https://iclr-blogposts.github.io/2025/blog/fisher/>
- InfoQ. (2025). Meta open sources LlamaFirewall for AI agent combined protection. <https://www.infoq.com/news/2025/05/llamafirewall-agent-protection/>
- Kirkpatrick, J., et al. (2017). Overcoming catastrophic forgetting in neural networks. DeepMind. <https://deepmind.google/blog/enabling-continual-learning-in-neural-networks/>
- Kwisatz. (2025). When AI becomes liquid assets. <https://www.kwisatzh.com/p/when-ai-becomes-liquid-assets>
- Li, Z., & Hoiem, D. (2017). Learning without Forgetting. <https://arxiv.org/abs/1606.09282>
- Liang, et al. (2024). A survey on continual learning for LLMs (ACM Computing Surveys, arXiv:2407.19354). <https://www.alphaxiv.org/overview/2407.19354>
- LLaMA-Factory. (n.d.). LLaMA-Factory GitHub. <https://github.com/hiyouga/LLaMA-Factory>
- Malladi, S., et al. (2023). MeZO: Fine-tuning language models with just forward passes. <https://arxiv.org/abs/2305.17333>
- Meta. (2025). LlamaFirewall: An open source guardrail system for building secure AI agents. <https://ai.meta.com/research/publications/llamafirewall-an-open-source-guardrail-system-for-building-secure-ai-agents>
- Misevolution (Shanghai AI Lab, et al.). (2025). Misevolution (arXiv:2509.26354). <https://arxiv.org/abs/2509.26354>
- O-LoRA. (2023). Orthogonal subspace learning for continual learning (arXiv:2310.14152). <https://arxiv.org/abs/2310.14152>
- PChome. (2025). MediaTek Dimensity NPU on-device LoRA training. <https://article.pchome.net/content-2185272.html>
- Ruanfujia. (2026). GitHub Copilot statistics. <https://www.ruanfujia.com/post/11578670/>

- Chromeosphere. (2026). GitHub Copilot statistics 2026. <https://chromeosphere.com/github-copilot-statistics-2026>
- AI Star Map. (2025). Hugging Face. <https://www.aistarmap.com/aitool/hugging-face>
- TechOrange. (2025). McKinsey deploys AI agents. <https://techorange.com/p/257957/>
- 投资界. (2025). McKinsey AI agents 转载. <https://www.tzzzs.com/p/52003/>
- 中华全国律师协会. (2025). AI 法律责任相关声明. <https://www.acla.org.cn/info/365d75ad55ff4588bb3d3cb0ee242519>
- 周兆成. (2026). AI 法律风险评论. <https://new.qq.com/rain/a/20260625A09SFP00>
- Wang, et al. (2025). iPFL: Incentive-driven personalized federated learning (Nature Communications). <https://www.nature.com/articles/s41467-025-62959-5>
- Wang, & Zhao. (2025). Federated learning challenges. <https://www.sciencedirect.com/science/article/pii/S2096720925001307>
- WhatLLM. (2026). Open-source vs proprietary LLMs 2025. <https://www.whatllm.org/blog/open-source-vs-proprietary-llms-2025>
- Zhou, et al. (2025). GSQ-Tuning (ACL Findings). <https://aclanthology.org/2025.findings-acl.1178/>
- Zylos Research. (2026). Continual learning & catastrophic forgetting in AI agents. <https://zylos.ai/research/2026-04-09-continual-learning-catastrophic-forgetting-ai-agents/>
- 杭州网 (Hangzhou Net). (2026). Qwen 生态规模. https://ehangzhou.gov.cn/2026-01/13/c_296686.htm
- 日照市大数据局. (2025). 日照港 DeepSeek-R1 私有化部署. http://dsjzj.rizhao.gov.cn/art/2025/3/6/art_85030_10300035.html
- 创业邦. (2025). 清华极数工业大模型. <https://m.cyzone.cn/article/812619.html>
- 21世纪经济报道. (2025). 开源闭源路线之争. <https://www.21jingji.com/article/20250402/herald/a0d8c7e12a5e39448dacb4aa309a5b92.html>
- 人保财险. (2025). 国内首批生成式 AI 侵权险. <https://finance.sina.cn/2025-06-13/detail-inezwrzq6222310.d.html>

待完善事项

- 第 2 章可进一步交代 Mistral / Llama 家族的具体版本谱系与许可差异（非阻塞，正文已含 Llama/Mistral/Qwen/DeepSeek 家族）。
- 命题②"OpenAI Dilemma"建议补充具名来源（如 OpenAI 2025 年开放权重模型公告），当前以结构性张力表述。
- 少量软性表述已在终稿补加超链接（Fortanix、21 世纪经济报道、CACM、InfoQ、LlamaFirewall、人保财险）。
- 三组权力格局命题与笔记推演的潜在风险均按"受争议命题 / 非既定事实"平衡呈现，未进行单边定论。
- 全程未触发硬性审稿退回；5 章均一轮 PASS，上述为审稿人提出的非阻塞优化建议。

本报告由 AI 深度研究团队生成，重要决策请经专业人员核验。所有引用来源请用户在重要场景下二次核验时效性与真实性。原创笔记《资源-开源持续学习重塑工业商业》仅作框架锚点，未入参考文献、稿内未自引。